

NVFP4 → HiF4 深度调研

项目：2026 华为算法大赛初赛 - 高精度 4Bit 数值转换算法

调研时间：2026-08-31

范围：NVFP4、HiF4、Linear 二阶量化、Attention Q/K/V 量化与等价变换

1. 调研问题

比赛给出的参考值不是模型最初的 FP16/FP32 张量，而是 NVFP4 数据按照固定规则反量化后的 BF16 值。参赛算法需要把这些值重新编码成合法 HiF4 参数，并尽可能保持 Linear 和 Attention 的计算结果。

因此，本题与普通“把高精度模型压成 4 bit”不同。源数据已经经历一次 NVFP4 量化，算法只能减少第二次格式转换新增的误差，不能恢复 NVFP4 已经丢失的信息。

NVFP4 参数

↓ 固定反量化

BF16 参考张量

↓ 选择合法 HiF4 参数

HiF4 重构张量

↓

比较 Linear / Attention 输出误差

调研主要回答三个问题：NVFP4 与 HiF4 的结构差异为什么导致转换误差；Linear 中为什么 Hessian/GPTQ 比普通 Tensor MSE 更合理；Attention 中为什么 Q/K 公共基底、互逆缩放和对侧协方差可能有效。

2. NVFP4 与 HiF4 的格式差异

NVFP4 和 HiF4 都不是单独一种 4-bit 元素格式，而是“4-bit 元素 + 分组共享缩放元数据”的微缩放体系。两者平均都约为 4.5 bit/value，但表示精度的分配方式不同。

特征	NVFP4	HiF4
元素格式	E2M1	S1P2 (论文也称 E1M2)
元素非负码值	0、0.5、1、1.5、2、3、4、6	0~1.75, 步长 0.25
基本分组	16 元素	64 元素
共享尺度	E4M3 per-16, 另有 FP32 tensor scale	E6M2 per-64, 加两层二值微指数
平均存储	约 4.5 bit/value	4.5 bit/value
主要特点	小分组、局部 scale 精细	大分组、元素精度更高、树状局部 scale

2.1 NVFP4

NVFP4 的 4-bit 元素使用 E2M1。每 16 个元素共享一个 E4M3 scale，整个 Tensor 还可以共享一个 FP32 全局 scale。完整解码关系为：

$$x_i = q_i s_{\text{blocks_tensor}}$$

NVIDIA 官方 direct-cast 的基本思路是：先由全 Tensor 最大值确定全局尺度，再由每 16 元素最大值确定 E4M3 block scale，最后把归一化元素舍入到 E2M1。由于 block scale 本身还要量化为 E4M3，direct-cast 的实际尺度并不总是连续空间中的最优尺度。

NVFP4 的训练 recipe 还可能包含随机 Hadamard 变换、二维缩放、梯度随机舍入和选择性高精度层。这些属于完整训练方法，不是 NVFP4 基础格式或本题反量化公式的一部分。

2.2 HiF4

HiF4 每 64 个元素构成一个单元：64×4 bit 元素加 32 bit 缩放元数据，总计 288 bit，即 4.5 bit/value。元素使用 S1P2，非负幅值为：

$$0, 0.25, 0.5, 0.75, 1, 1.25, 1.5, 1.75$$

64 元素共享一个 E6M2 基础尺度；每 8 元素有一个二级微指数，每 4 元素有一个三级微指数。两个微指数都只能选择 0 或 1，即分别乘以 1 或 2：

$$x_i = s_{\text{E6M2}} 2^{e_{8,i}} 2^{e_{4,i}} q_i$$

S1P2 最大幅值 1.75，再乘两级最大微尺度 2×2，局部最大幅值为 7。官方转换流程因此围绕“64 元素全局最大值、8 元素局部最大值、4 元素局部最大值”逐级生成 scale，最后舍入 S1P2。

2.3 转换为什么不是简单查表

NVFP4 的四个 16 元素 block 合并成一个 HiF4 64 元素 block 后，原来的四个 E4M3 scale 不能直接复制到一个 E6M2 和两级微指数中。HiF4 的一个基础 scale 同时影响 64 个数，lv2 影响 8 个数，lv3 影响 4 个数，因此尺度选择与元素舍入是耦合的组合问题。

逐元素最近舍入只能在尺度已固定时局部最优，不能保证整个 64 元素 block 最优。由最大值决定 scale 主要保证不溢出，也不等价于最小重构误差，更不等价于最小 Linear 或 Attention 输出误差。

3. Linear: 从 Tensor MSE 到输出误差

设线性层输出为 $Y=XW^T$, 量化权重为 $\hat{W}$, 权重误差为 $D=W-\hat{W}$ 。输出误差为:

$$\|XD^T\|_F^2 = \sum_r d_r^T (X^T X) d_r$$

这说明权重中相同大小的误差, 在不同输入方向上代价不同。普通权重 MSE 相当于使用单位矩阵衡量误差, 而真实 Linear 输出误差由校准 Activation 的二阶统计 $H=X^T X$ 决定。

3.1 OBQ 与 GPTQ

Optimal Brain Compression (OBC/OBQ) 把量化写成二阶优化问题。某个权重被固定到量化值后, 舍入残差不是直接丢弃, 而是按照逆 Hessian 分配到尚未量化的自由变量, 使校准输出尽量保持不变。

GPTQ 延续这一思想, 但采用固定列顺序、共享 Hessian、阻尼、Cholesky 分解和批量延迟更新, 使大模型的一次性权重量化具备可扩展性。它的核心不是“补偿项乘 2”, 也不是算法规定必须执行两遍。

迁移到本题时, Hessian 目标仍然成立, 但 HiF4 不是相互独立的标量量化: 一个 block 内的 E6M2、lv2、lv3 和 mant 彼此耦合。因此更准确的理解是, GPTQ 可以给合法 HiF4 候选提供二阶评价和残差传播, 但不能把原论文中的独立标量舍入原样复制过来。

3.2 SmoothQuant 与 AWQ

SmoothQuant 使用成对的逐通道缩放, 把 Activation 的量化难度迁移到 Weight:

$$X' = X \text{diag}(s)^{-1}, \quad W' = W \text{diag}(s)$$

在浮点下有 $X'W'^T = XW^T$ 。这种等价预条件可以降低 Activation 离群通道对共享 scale 的影响。

AWQ 同样利用 Activation 统计识别重要权重通道, 并通过成对缩放保护这些通道。两者共同说明: 重要性不能只由 Weight 自身的幅值判断, 输入分布决定了权重误差对输出的影响。

不过, SmoothQuant 原本面向 W8A8, AWQ 原本面向 weight-only INT4。它们对 HiF4 的价值是“等价缩放和重要通道保护”的思想, 而不是论文中的精度数字可以直接复现。只有缩放与逆缩放都能合法保留时, 浮点函数才保持不变。

3.3 Linear 方法的适用边界

二阶方法可以减少 NVFP4→HiF4 的新增误差, 但不能恢复 NVFP4 中已经丢失的原始权重。有限校准样本还可能使 Hessian 病态或过拟合, 通常需要阻尼。GPTQ 的处理顺序、block 边界以及补偿后再次进行 HiF4 投影, 也会使理论上的二次型下降不一定完全转化为平台得分提升。

4. Attention: Q、K、V 的误差传播不同

Attention 的基本形式为:

$$L = QK^T / \sqrt{d}, \quad P = \text{softmax}(L), \quad O = PV$$

如果 $\hat{Q} = Q + E_Q$, $\hat{K} = K + E_K$, 则 logits 误差为:

$$\Delta L = E_{QK}^T + Q E_K^T + E_Q E_K^T$$

因此 Q 的误差由 K 的方向和能量加权，K 的误差由 Q 加权。分别最小化 Q-MSE 和 K-MSE，并不等价于最小化 logits 误差。

V 的误差则通过：

$$\Delta O = P(V - V')$$

传递到输出。被高 Attention 权重访问的 token 更重要，普通 V Tensor MSE 也不能完全代表 Attention 输出误差。KIVI 的论文实验显示，K/V 选择不同量化粒度时，张量重构误差和最终 Attention 误差的排序可能明显不同。

5. 公共谱基底为什么可能有效

5.1 浮点计算保持不变

对任意正交矩阵 R ：

$$Q' = QR, \quad K' = KR$$

则：

$$Q'K'^T = QRR^TK^T = QK^T$$

更一般地，对可逆矩阵 R ，使用 $Q' = QR$ 、 $K' = KR^{-T}$ 也保持乘积不变。这提供了一族浮点等价的 Q/K 表示。

5.2 HiF4 对坐标系敏感

HiF4 固定每 64 元素分组，并在 64/8/4 层级共享尺度，因此它不是旋转不变量。同一个向量在不同坐标系中可能具有完全不同的 block 最大值、离群值位置和 scale 利用率。

公共谱基底可由 Q/K 联合二阶统计构造，例如：

$$C = Q^T Q + K^T K, \quad C = R \Lambda R^T$$

在新基底中，相关方向被解耦，主要能量方向被重新排列，离群能量也可能分散到更多通道。它不是截断 PCA，不删除维度；作用只是从浮点等价表示中选择更适合固定 block 和共享 scale 的坐标系。

Q、K 不能各自独立做 PCA。若使用不同的 R_Q 和 R_K ，通常有 $R_Q R_K^T \neq I$ ，会直接改变 logits。公共基底有效的前提正是两侧严格匹配。

5.3 旋转相关研究

QuaRot 使用计算不变的 Hadamard 旋转平滑离群值，并展示了 W4A4KV4 的可行性。SpinQuant 进一步指出不同旋转的量化效果差异很大，通过学习正交旋转提高量化精度。这些工作支持“等价旋转可以改变低比特量化难度”，但其 INT4 结果不能直接当成 HiF4 的比赛收益。

DuQuant 使用 block-wise rotation、通道置换和再次旋转，把 massive outlier 分散到多个 block；RPTQ 根据通道范围聚类并重排。它们与 HiF4 的关联在于：即使全局方差不变，只要降低同一 64 元素 block 内的动态范围差异，共享 scale 的有效精度就可能提高。

5.4 对角互逆缩放

QServe/SmoothAttention 使用 Q/K 互逆逐通道缩放，把 K 的离群通道量化难度迁移到 Q：

$$(Q\Lambda)(K\Lambda^{-1})^T=QK^T$$

这与参考提交中的 Q/K smooth scale 高度相似。对角缩放比全旋转成本更低、数值更稳定，但本题中 Q 和 K 都需要量化，不能只降低 K 的误差而无限放大 Q，必须同时考虑两侧的量化结果。

5.5 公共基底的限制

联合协方差的特征向量只对角化二阶统计，并不直接最小化离散 HiF4 编码后的 Attention loss。特征值接近时，特征向量还可能不稳定。非正交变换虽然保持乘积，但条件数过大可能把动态范围从一侧转移到另一侧并放大量化噪声，因此 Q/K 都量化时，正交或近正交变换通常更稳健。

RoPE 也是重要边界：如果旋转直接施加在 Post-RoPE 的 Q/K 上，内积恒等容易成立；如果试图提前融合到投影权重，变换必须与 RoPE 可交换。GQA 中多个 Q head 共用一个 K head，联合统计应汇总对应 Q 组的二阶贡献，而不是先对原始 Q 求均值，否则可能发生正负抵消。

6. K/V 量化研究带来的认识

KIVI 观察到 K 的离群值更倾向于固定在通道维，因此采用 K per-channel、V per-token 的不同粒度。KVQuant 也强调 K 的通道离群值、层敏感度和异常值处理。这些论文研究的是 KV Cache，其系统吞吐数字不能直接迁移到本赛题，但其分布观察解释了为什么 K 更适合由 Q 的全协方差衡量，而 V 更需要关注 Attention 权重。

赛题的 HiF4 格式和 block 边界固定，通常不能照搬 per-channel/per-token 数据类型，也不能额外保存稀疏高精度 outlier。可以直接继承的是误差分析：Q/K 应看 logits 或 Attention 输出，V 应看 $P\Delta V$ ，Tensor MSE 只能作为辅助指标。

7. 方法与本题题的关系

方法	原始目标	对本题有价值的思想	不能直接照搬的部分
GPTQ / OBQ	权重量化	Hessian 输出误差、残差补偿	独立标量量化假设
SmoothQuant	W8A8	成对互逆缩放、平滑离群值	INT8 结论与相邻层折叠方式
AWQ	INT4 weight-only	Activation 感知的重要通道	原论文码本和精度结果
QuaRot	W4A4KV4	正交旋转保持函数、平滑离群值	Hadamard 不一定最适合 HiF4
SpinQuant	学习旋转	旋转选择决定量化效果	训练成本和原量化目标
QServe	低比特推理	Q/K 对角互逆平滑	原方法主要保护 K
KIVI / KVQuant	KV Cache	K/V 分布差异与输出敏感度	缓存粒度和系统加速数字
DuQuant / RPTQ	激活量化	重排能改善 block 内范围	变换必须可被合法抵消

整体上，相关研究可以归纳为两层。格式层负责生成严格合法的 HiF4 参数并控制 block 重构误差；计算层利用 Linear Hessian、Q/K 等价变换和 Attention 误差传播，判断哪些合法编码对最终输出更重要。两层目标相关但并不等价。

8. 结论

NVFP4→HiF4 的困难来自两种微缩放结构不一致：16 元素 E4M3 scale 必须重新组织为 64/8/4 的 HiF4 树状尺度。由于共享 scale，一个元素或局部离群值会影响同组其他元素，转换本质上是带格式约束的组合量化问题。

Linear 中， $X^T X$ 决定权重量化误差对输出的影响，解释了 Hessian/GPTQ、Activation 感知缩放为什么比单纯 Weight MSE 更有依据。Attention 中，Q/K 的误差由对侧张量加权，V 的误差由 Attention 权重加权，因此三个张量不应使用完全相同的误差代理。

公共谱基底的价值不在 PCA 本身，而在利用 Q/K 的正交不变性：浮点 QK^T 保持不变，但能量和离群值被重新组织到更适合 HiF4 固定 block 与共享 scale 的坐标系。它具有明确的数学依据，也受到 QuaRot、SpinQuant 等旋转量化工作的支持；但它是否优于恒等基底，最终仍由具体 HiF4 编码后的 Attention 输出误差决定。

9. 一手资料

格式与硬件

- [1. NVIDIA Transformer Engine: NVFP4](#)
- [2. Pretraining Large Language Models with NVFP4](#)
- [3. HiFloat4 Format for Language Model Inference](#)
- [4. HiFloat4 官方白皮书](#)
- [5. HiFloat4 官方实现](#)
- [6. Microscaling Data Formats for Deep Learning](#)

Linear 量化

1. Optimal Brain Compression
2. GPTQ
3. SmoothQuant
4. AWQ
5. OCP Microscaling Formats MX v1.0

Attention 与 KV 量化

1. QuaRot
2. SpinQuant
3. QServe
4. KIVI
5. KVQuant
6. DuQuant
7. RPTQ