

NVFP4 → HiF4 项目调研与方案总结

项目：2026 华为算法大赛初赛 - 高精度 4Bit 数值转换算法

更新时间：2026-08-31

1. 项目目标

本项目需要将 NVIDIA NVFP4 数据转换成昇腾 HiF4 参数，并尽量保持大模型 Linear 和 Attention 的计算结果不变。

NVFP4 Weight / Activation / Q / K / V
↓ 固定反量化
BF16 参考值
↓ 参赛算法
合法 HiF4 参数
↓
Linear / Attention 输出误差评测

比赛参考值是给定 NVFP4 数据反量化后的结果，不是模型最初的 BF16/FP32 数据。因此，本质上是一次受 HiF4 格式约束的二次量化。

单个用例得分为：

$$\text{Score} = (\text{MSE}_{\text{STD}} - \text{MSE}_{\text{PLAYER}}) / \text{MSE}_{\text{STD}}$$

参赛算法误差低于标准 HiF4 算法时得正分，高于标准算法时得负分。

2. 为什么需要这种转换

FP4 可以降低大模型的权重、Activation 和 KV Cache 存储及搬运开销。但不同硬件平台采用的 FP4 格式并不一致：

特征	NVFP4	HiF4
元素格式	E2M1	S1P2
block 大小	16	64
局部 scale	E4M3	两层 {1,2} 微尺度
基础 scale	FP32 per-tensor	E6M2 per-64
非负元素值	0、0.5、1、1.5、2、3、4、6	0~1.75，步长 0.25

NVFP4 的四个 16 元素 block 合并成一个 HiF4 64 元素 block 后，原有 scale 无法直接复制。算法必须重新选择 E6M2、两级微尺度和 mant。

该项目面向的实际价值是：减少模型跨硬件平台部署时重新训练或重新量化的成本，并提升既有 NVFP4 模型资产在 HiF4 平台上的兼容性。

3. 赛题任务

3.1 Linear

输入：

- NVFP4 Weight;
- Calibration Activation;
- 在线 Test Activation。

目标：

$$\min \text{MSE}(X_{\text{HiF4}}W_{\text{HiF4}}^T, X_{\text{NVFP4}}W_{\text{NVFP4}}^T)$$

校准函数负责量化 Weight 并生成 `activation_state`；动态函数使用 state 量化当前 Activation。

3.2 Attention

输入：

- Calibration Q/K/V;
- Test Q/K/V;
- Q head、KV head 和 head dimension。

目标：

$$\min \text{MSE}(\text{Attention}(Q_{\text{HiF4}}, K_{\text{HiF4}}, V_{\text{HiF4}}), \text{Attention}(Q_{\text{NVFP4}}, K_{\text{NVFP4}}, V_{\text{NVFP4}}))$$

校准函数生成 `q_state`、`k_state` 和 `v_state`，在线阶段分别量化 Q、K、V。

3.3 关键约束

- 必须实现任务书规定的六个接口；
- HiF4 参数必须严格合法；
- state 只能包含基础类型、CPU Tensor、list/tuple 和字符串键 dict；
- 单次提交总运行时间不超过五分钟；
- 禁止计算 `A @ W` 后利用结果反向拟合 `Q(A)`；
- `self_check.py` 只检查格式，不代表精度得分。

4. 固定的数值规则


4.1 NVFP4 反量化

比赛已经确定 NVFP4 反量化方法：

```
x = quant_float.unflatten(-1, (-1, 16))
x = x * scale_float.unsqueeze(-1)
x = x.flatten(-2, -1).to(torch.bfloat16)
```

算法不需要解析原始 4-bit bitstream，也不能改变判题器对 NVFP4 的解释。

NVFP4：16 元素微块 + 两级尺度



图中以连续 64 个元素为例：NVFP4 实际保留 4 个独立的 per-16 E4M3 局部尺度，并与全 Tensor 的 FP32 scale 共同完成反量化。

4.2 HiF4 反量化

HiF4 每 64 个元素包含：

- 1 个 E6M2 `scale_factor`；
- 8 个 `scale_lv2`，每个控制 8 个元素；
- 16 个 `scale_lv3`，每个控制 4 个元素；
- 64 个 `sign/mant`。

固定反量化公式：

$$\hat{x} = \text{sign} \times \text{mant} \times \text{scale}_{lv3} \times \text{scale}_{lv2} \times \text{scale}_{\text{factor}}$$

合法范围：


```

scale_factor: E6M2
scale_lv2    : 1 或 2
scale_lv3    : 1 或 2
sign        : -1、0 或 1
mant        : 0~1.75, 步长 0.25

```

反量化规则是确定的；比赛需要优化的是如何选择这些参数。

HiF4: 64 → 8 → 4 的三级缩放树



关键差异: NVFP4 的 4 个 per-16 scale, 必须重新组织成 HiF4 的 1 个根 scale + 8 个 lv2 + 16 个 lv3

HiF4 用一个 E6M2 根尺度覆盖 64 个元素，再用 8 个 lv2 和 16 个 lv3 恢复局部动态范围。NVFP4 的四个局部尺度无法直接复制，因此转换时必须重新选择整棵缩放树。

5. 当前 baseline 的方案

当前 `baseline.py` 使用“格式内搜索 + 校准二阶补偿”的两层结构。

5.1 第一层: HiF4 格式内搜索

`_encode()` 的流程是：

1. 将四个 NVFP4 block 合并为 64 元素；
2. 从 `max_abs/7` 附近选取多个 E6M2 候选；
3. 在 HiF4 树状约束下选择 lv2/lv3；
4. 将每个元素舍入到 S1P2；
5. 对给定离散参数重新拟合连续最优 scale；
6. 将 scale 舍入到最近合法 E6M2；
7. 选择重构 MSE 最小的候选。

这比官方单纯由局部最大值决定 scale 的方式更强，但目前搜索范围较窄，scale 回归后也没有再次更新 mant。

5.2 第二层：SVD 二阶统计

Linear 中，设权重量化误差为：

$$D=W-\hat{W}$$

校准输入为 A ，最终输出误差为：

$$\|AD^T\|_F^2=\sum_r d_r^T(A^TA)d_r$$

因此不同通道的误差重要性由 A^TA 决定。baseline 使用截断 SVD 近似该矩阵：

$$A\approx U_k\Sigma_kV_k^T$$

$$A^TA\approx V_k\Sigma_k^2V_k^T$$

这样可以用 `[rank, hidden_size]` 的低秩 state 表示重要方向，避免保存完整 Hessian。

5.3 Schwarz 分组舍入

普通最近邻对每个元素独立选择 floor 或 ceil。当前方案每次联合枚举一组元素的上下舍入组合，并根据全局投影误差更新后续决策。

它允许以下现象：某个元素不选择离自身最近的值，但它产生的误差与其他通道误差抵消，最终矩阵乘误差反而更小。

这与 GPTQ 的二阶误差补偿思想一致。

6. 参考提交与版本路线分析

6.1 版本定位

根据现有成绩记录，几个关键版本的定位如下：

版本	平台 V2 得分	核心路线	版本定位
V42	24839	Attention Q/K 公共谱基底与互逆变换	当前最高分综合版本，作为最终方案上界
V37	24438	V42 的简化父版本	结构更简单、运行更稳定
V32	-	Linear Hessian/GPTQ	独立研究权重量化误差补偿
V33	-	Attention K 全协方差选择	补充研究，平台耗时接近 300 秒

这四个版本不是简单的连续增强关系，而是三条研究路线：

Attention 主线：V37（稳定基线） -> V42（公共谱基底）

Linear 支线： V32（Hessian/GPTQ）

Attention 支线： V33（K 全协方差，精度/耗时探索）

V42 比 V37 高 401 分，约提升 1.64%。两者的差异表明公共谱基底带来了可见收益，同时 V37 仍具有结构简单、运行稳定的特点。

6.2 V42: Q/K 公共谱基底与互逆变换

Attention logits 由 QK^T 决定。对任意可逆矩阵 R ，存在恒等关系：

$$(QR)(KR^T)^T = QK^T$$

因此可以在不改变浮点 logits 的前提下，把 Q 和 K 变换到同一个公共基底：

$$\begin{aligned} Q' &= QR \\ K' &= KR^T \end{aligned}$$

若 R 来自 Q/K 联合统计的特征向量或谱分解，就可以把主要能量方向集中、解耦或重新排序，使 HiF4 的 64 元素分块和共享 scale 更容易表示。其真正目标不是让 Q 、 K 各自的 Tensor MSE 最小，而是让二者的乘积误差更小。

该方法有效的关键是“公共”和“互逆”： Q/K 必须共享同一坐标系，并使用严格配对的 R 与 R^T 。若两侧独立选基底，或者只旋转一侧，浮点乘积本身就会改变。

其局限主要来自谱基底的数值稳定性、 R 的条件数、GQA 的多头统计聚合以及在线变换成本。浮点恒等也不代表量化后必然更优，平台得分才是该变换实际效果的最终体现。

6.3 V37: 稳定的 Attention 父版本

V37 是 V42 的父版本，得分只低 401，但结构更简单、运行更稳定。它保留了 Attention 路线的主体，同时没有 V42 公共谱基底带来的额外复杂度，因此能够清楚反映谱基底模块对得分和稳定性的影响。

6.4 V32: Linear Hessian/GPTQ 独立路线

Linear 输出误差满足：

$$\|A(W-W)^T\|_F^2 = \sum_r d_r^T (A^T A) d_r$$

V32 的 Hessian/GPTQ 路线直接围绕 $H=A^T A$ 优化权重量化误差：当前列量化后，把该列残差按逆 Hessian 传播到尚未量化的列，从而允许不同通道的误差相互补偿。

这条路线与 Attention 公共谱基底基本正交，反映的是 Linear 权重量化中的二阶误差补偿能力。

6.5 V33: Attention K 全协方差路线

K 的量化误差通过 $Q \Delta K^T$ 进入 logits，因此用对应 Q 的协方差作为 K 的二阶代理是合理的。V33 使用更完整的协方差，可以描述通道间相关性，比单纯逐通道重要性更接近最终 logits 目标。

但平台耗时接近 300 秒，已经逼近总时限。这说明全协方差虽然表达能力更强，但矩阵构造、分解、逆矩阵保存和逐块修复带来了明显的工程成本。

6.6 当前 `reference/submissions/solution.py` 的可验证实现

参考方案目录实际只有一个 `reference/submissions/solution.py`，没有 V37/V32/V33 的独立源码。该文件实现了完整六接口闭环。

在 Linear 部分，它先进行通用 HiF4 参数搜索，再根据 Activation 二阶矩构造 2 的整数幂互逆预条件，使变换后的 Weight 与在线 Activation 仍保持原矩阵乘关系。随后代码构造 64 维 block Hessian，比较自然序、逆序和 Hessian 对角降序，并继续进行 128 维相邻 block、尾部样本 Pareto 门控和 Top-4 联合修复。

在 Attention 部分，它按照 Q/K 最大值构造互逆平滑缩放，使 Q 除以 scale、K 乘以 scale 后仍保持内积不变。Q 的 Hessian 来自 K 的协方差，K 的 Hessian 来自同组全部 Q head 的协方差。V 只使用二阶能量和少量最大值信息构造逐通道重要性。各模块在 shape、有限值、Cholesky 或 state 校验失败时都会退回普通合法 HiF4 量化。

需要特别注意版本标识：该文件明确设置 `rotation_group_size=0`，并记录 `stable-v3-basis-no-rotation`。因此它**没有实现 V42 描述中的公共谱旋转**。在获得各版本原始文件前，不能把当前 `solution.py` 直接认定为 V42；它更像“Linear 强化 + Attention 平滑/Hessian”的另一套综合实现。

7. 外部分享观点与现有实现理解

本节汇总 Softmax、GPTQ 以及当前参考提交中值得关注的内容。这些观点用于解释方案为什么可能有效，不作为后续方案设计。

7.1 Softmax 对 Q/K 误差的影响

对任意常数 c ，Softmax 满足行平移不变性：

$$\text{softmax}(z+c1)=\text{softmax}(z)$$

因此，Q/K 量化引起的 logits 误差中，每一行的常数偏移不会改变 Softmax 输出。直接使用 logits MSE 会把这种无害偏移也计入误差，而行中心化 logits MSE 更接近 Softmax 真正敏感的方向。不过，量化误差通常不能自由转化为行常数，因此该性质主要用于理解误差，而不能单独证明某种量化方法一定有效。

7.2 Softmax 对 V 误差的影响

设 $P=\text{softmax}(L)$ ，则每行权重之和恒为 1，即：

$$P1=1$$

Attention 输出为 $O=PV$ 。V 的量化误差经过 P 加权后传递到输出，因此高 Attention 权重访问的 token 更重要，普通 V Tensor MSE 不能完全代表最终 Attention MSE。同时，如果所有 V token 都带有相同偏移，该偏移会完整保留，而不会被 Softmax 抵消。

7.3 对“GPTQ 做两倍”的理解

“GPTQ 做两倍”缺少上下文，可能表示执行两遍 GPTQ、扩大 block 或搜索预算，也可能表示放大补偿项。前两种解释属于计算预算增加，最后一种则会改变逆 Hessian 推导出的补偿关系，存在过补偿和数值不稳定风险。

当前 baseline 的“先格式搜索，再进行 Schwarz 多轮更新”和参考提交中的多顺序 Hessian 修复，都具有重复检查、传播和接受更优量化结果的特点，与“两遍优化”在概念上接近。但仅凭这句话无法确认分享者的原意，因此报告只保留其可能含义，不把它视为已经确定的算法步骤。

7.4 当前实现的整体认识

当前参考提交将多种思路组合在一起：HiF4 合法参数搜索负责控制基础重构误差；Linear 使用互逆预条件和 Hessian/GPTQ 修复，使权重与 Activation 的量化误差能够按输出敏感度补偿；Attention 使用 Q/K 互逆平滑和对侧协方差，让 Q 的误差由 K 的统计衡量、K 的误差由 Q 的统计衡量；V 则采用较保守的逐通道能量权重。

这些方法的共同点是：不再只追求单个 Tensor 的重构 MSE，而是利用 Linear 或 Attention 的计算结构衡量哪些误差真正影响最终输出。与此同时，当前参考文件没有实现 V42 所描述的公共谱旋转，因此版本说明与现有代码仍需分开理解。

8. 资料

1. [比赛中文任务书](#)
2. [HiFloat4 Format for Language Model Inference](#)
3. [HiFloat4 官方说明](#)
4. [NVIDIA NVFP4 官方文档](#)
5. [Pretraining Large Language Models with NVFP4](#)
6. [GPTQ](#)
7. [SmoothQuant](#)
8. [AWQ](#)
9. [QuaRot](#)
10. [SpinQuant](#)
11. [KIVI](#)